Universidade de São Paulo

**José Otávio Junqueira Ramos**
**Luísa Domingues Santello**

# Proposta de Pesquisa

# Aprimoramento de Sistemas de Recomendação em Investimentos Financeiros por meio da Análise de Sentimentos

São Carlos - SP
2025

# Proposta de Pesquisa

## Aprimoramento de Sistemas de Recomendação em Investimentos Financeiros por meio da Análise de Sentimentos

**Autores:**
José Otávio Junqueira Ramos
Luísa Domingues Santello

Universidade de São Paulo
Instituto de Ciências Matemáticas e de Computação
Curso de Engenharia de Computação

São Carlos - SP
2025

# Sumário

**Sumário** . . . . . **1**

**1 Introdução** . . . . . **2**
1.1 Panorama Geral e Desafios . . . . . 2

**2 Justificativa** . . . . . **2**

**3 Objetivos** . . . . . **3**
3.1 Objetivo Geral . . . . . 3
3.2 Objetivos Específicos . . . . . 3

**4 Conceitos Teóricos** . . . . . **4**
4.1 Redes Neurais Artificiais . . . . . 4
4.2 Processamento de Linguagem Natural (PLN) . . . . . 4
4.3 Utilização da Rede Neural SenFinBERT-PTBR . . . . . 5
4.4 Coleta de Dados com a Biblioteca Scrapy . . . . . 5
4.5 Armazenamento de Dados com a Biblioteca MongoDB . . . . . 5
4.6 Recomendação de Carteira para Day Trade com Python . . . . . 5

**5 Proposta de Trabalho** . . . . . **6**
5.1 Base de Dados . . . . . 6
5.2 Processamento e Análise dos Dados . . . . . 6
5.3 Construção do Algoritmo de Decisão . . . . . 6
5.4 Avaliação de Eficiência . . . . . 7
5.5 Divulgação do Projeto . . . . . 7

**6 Cronograma** . . . . . **7**

**7 Resultados Esperados** . . . . . **8**

**Referências** . . . . . **9**

# 1 Introdução

## 1.1 Panorama Geral e Desafios

O mercado financeiro contemporâneo é caracterizado por alta volatilidade e sensibilidade a fatores econômicos, políticos e comportamentais [Park e Irwin 2004]. Nesse cenário, a disseminação de informações em redes sociais e notícias tem se tornado um importante canal para a formação de expectativas dos investidores, afetando diretamente os preços de ativos financeiros [Rao e Jelvis 2022].

Com a ampliação do volume de dados disponíveis e os avanços em Processamento de Linguagem Natural (PLN), tornou-se possível extrair sentimentos, opiniões e tendências de textos não estruturados, o que abre caminho para estratégias de previsão de mercado baseadas na percepção coletiva dos agentes [Capati 2021]. Esses dados alternativos, quando integrados a modelos de decisão automatizada, podem fornecer sinais complementares à análise técnica e fundamentalista tradicional [Lommers, Harzli e Kim 2021].

Nesse contexto, o Aprendizado por Reforço (Reinforcement Learning – RL) surge como uma abordagem promissora para modelar a tomada de decisão em ambientes sequenciais e estocásticos, como é o caso do mercado financeiro. Segundo Sutton [Sutton e Barto 2018], o RL permite que agentes aprendam políticas ótimas por meio da interação com o ambiente, ajustando-se continuamente às mudanças. Aplicado ao trading, o RL possibilita adaptar estratégias conforme novos dados são incorporados, o que é especialmente útil diante da instabilidade e dos ciclos de mercado [Jiang, Olmo e Atwi 2024, Hambly, Xu e Yang 2023]

Entretanto, o uso de RL em finanças não é trivial. Abordagens tabulares, como o Q-Learning original [Watkins e Dayan 1992, Oliveira 2020], enfrentam problemas de escalabilidade e generalização em ambientes com alta dimensionalidade. Técnicas mais avançadas, como Deep Q-Network (DQN) [Mnih et al. 2015] e Proximal Policy Optimization (PPO) [Schulman et al. 2017], oferecem soluções mais robustas, mas introduzem novos desafios relacionados a overfitting, estabilidade do treinamento e definição de recompensas [Deng et al. 2016, Moody e Saffell 2001].

# 2 Justificativa

A análise de sentimentos vem ganhando destaque como uma abordagem eficaz para extrair informações valiosas a partir de grandes volumes de textos gerados por usuários em redes sociais, notícias e fóruns especializados. Tais informações, quando corretamente processadas, podem antecipar movimentos do mercado ao refletir a percepção e o humor dos investidores [Almiñana 2022].

No contexto da língua portuguesa, esse campo de estudo ainda é incipiente, como apontado por Santos [Santos 2022], devido à escassez de modelos linguísticos especializa-

dos e bases de dados anotadas com qualidade. Essa limitação motiva o uso de modelos como o FinBERT-PTBR, adaptado ao domínio financeiro em português, como parte de uma estratégia integrada de análise de sentimentos e aprendizado por reforço.

Do ponto de vista metodológico, o uso combinado de PLN com RL abre novas possibilidades para a construção de agentes inteligentes que reagem não apenas aos preços históricos, mas também ao fluxo contínuo de informações sociais. Estudos recentes demonstram que a adoção de algoritmos de RL — como DQN, PPO e Deep Deterministic Policy Gradient (DDPG) — pode melhorar significativamente o desempenho de estratégias automatizadas em ambientes voláteis [Nevmyvaka, Feng e Kearns 2006, Capati 2021, Oliveira 2024].

Além disso, trabalhos como o de Jiang et al. [Jiang, Olmo e Atwi 2024] e Hambly et al. [Hambly, Xu e Yang 2023] destacam o potencial do RL em tarefas como seleção de portfólio e execução de ordens, enquanto outros autores exploram a aplicação em contextos multiagente [Capati 2021], ampliando ainda mais o escopo de aplicação no setor financeiro.

Portanto, este projeto se justifica tanto pela inovação metodológica quanto pela aplicabilidade prática. A combinação de análise de sentimentos com RL tem potencial para gerar agentes de negociação mais adaptativos, contextualmente sensíveis e capazes de explorar novas fontes de informação relevantes para a tomada de decisão no mercado financeiro.

# 3 Objetivos

## 3.1 Objetivo Geral

Desenvolver um sistema que recomende carteiras de investimento com base na análise de sentimentos de postagens financeiras na internet, utilizando técnicas avançadas de Processamento de Linguagem Natural para apoiar decisões na bolsa de valores.

## 3.2 Objetivos Específicos

- Utilizar PLN para interpretar o sentimento de textos em português com foco no domínio financeiro, explorando modelos de linguagem de última geração, como a arquitetura BERT, com ênfase em modelos pré-treinados ou adaptados para o português brasileiro e o léxico financeiro, como o SenFinBERT-PTBR.

- Construir e ampliar uma base de dados atualizada com notícias financeiras para o treinamento e validação dos modelos.

- Desenvolver uma API em Python que utilize os dados classificados para recomendar operações de compra e venda de ETFs no mercado brasileiro.

- Validar o desempenho do modelo por meio da análise comparativa com indicadores financeiros tradicionais, como a taxa Selic e a volatilidade do mercado.
- Planejar e executar a divulgação científica e popular do projeto, incluindo a produção de vídeos explicativos para o YouTube.
- Simular os resultados obtidos no presente trabalho em uma corretora para a validação dos resultados
- Elaborar o relatório final compilando os resultados, discutindo limitações e propondo direções para pesquisas futuras.

# 4 Conceitos Teóricos

## 4.1 Redes Neurais Artificiais

Redes neurais artificiais (RNAs) são modelos computacionais inspirados no cérebro humano. Elas são compostas por unidades chamadas neurônios artificiais, que se organizam em camadas do tipo: entrada, ocultas e saída; as quais se conectam por meio de conexões ponderadas — as chamadas sinapses. O grande diferencial das RNAs é a capacidade de aprender com dados, ajustando esses pesos através de algoritmos de treinamento como o gradiente descendente. Um exemplo clássico e bastante conhecido é o Perceptron, proposto por Rosenblatt em 1958, que realiza classificações simples com base em exemplos já rotulados [Rezende 2003].

Hoje, essas redes têm uma ampla gama de aplicações, como reconhecimento de padrões, classificação de textos, previsão de séries temporais e, especialmente, análise de comportamento do mercado financeiro. Com grandes volumes de dados, é possível treinar redes capazes de prever oscilações de preços com base em informações como notícias em tempo real — desde que os dados sejam relevantes e bem rotulados.

## 4.2 Processamento de Linguagem Natural (PLN)

O Processamento de Linguagem Natural (PLN) é uma área da inteligência artificial voltada para o entendimento e a manipulação da linguagem humana por máquinas. Essa área engloba tarefas como análise sintática, identificação de entidades, análise de sentimentos, sumarização e tradução automática. O PLN busca extrair o significado de textos escritos em linguagem comum, sendo essencial para lidar com grandes volumes de dados textuais, como os presentes em redes sociais ou portais de notícias [Martins 2014].

## 4.3 Utilização da Rede Neural SenFinBERT-PTBR

O SenFinBERT-PTBR é uma adaptação do modelo BERT, desenvolvida especialmente para o português do Brasil com foco em textos do setor financeiro. Ele se destaca por usar atenção bidirecional, o que permite entender o contexto de uma palavra com base em outras ao seu redor — o que é crucial em textos técnicos ou ambíguos. Essa versão especializada é bastante útil para classificar e interpretar sentimentos em documentos financeiros, como relatórios de mercado, notícias ou postagens em redes sociais, relacionando-os ao comportamento de ativos [IA Expert 2020].

## 4.4 Coleta de Dados com a Biblioteca Scrapy

Para extrair dados da web de forma automatizada, uma das ferramentas mais eficientes é a biblioteca Scrapy, desenvolvida em Python. Ela permite criar spiders — pequenos programas que navegam por páginas web — para coletar informações como textos, títulos, datas e links. Esse tipo de coleta é essencial em projetos que exigem grande volume de dados, como análises financeiras ou mineração de informações em redes sociais [Scrapy - PyPI 2025].

## 4.5 Armazenamento de Dados com a Biblioteca MongoDB

MongoDB é um banco de dados NoSQL bastante utilizado quando há necessidade de armazenar informações com estrutura flexível. Ele usa documentos no formato BSON (uma versão binária do JSON), o que permite adicionar novos campos sem mudanças estruturais no banco. Isso é especialmente útil em projetos que lidam com dados variados e em constante mudança, como os extraídos da web. Além disso, o MongoDB é conhecido por sua boa performance e escalabilidade, o que o torna comum em soluções de big data, principalmente quando combinado com ferramentas como Scrapy [MongoDB Docs 2025].

## 4.6 Recomendação de Carteira para Day Trade com Python

Com Python, é possível desenvolver algoritmos que sugerem carteiras de ativos para operações de *day trade*, analisando dados históricos como preços, volumes e indicadores técnicos (como médias móveis, RSI e MACD). Bibliotecas como `pandas`, `numpy` e `matplotlib` ajudam na manipulação, análise e visualização dos dados. Além disso, modelos de PLN como o SenFinBERT-PTBR podem ser integrados a esse processo para incorporar o sentimento do mercado, extraído de notícias e redes sociais, à análise técnica tradicional [Filho 2022].

# 5 Proposta de Trabalho

## 5.1 Base de Dados

Esta pesquisa utilizará como ponto de partida a base de dados desenvolvida por Lucas L. Santos (2022) [Santos 2022], que reúne notícias relacionadas ao mercado financeiro brasileiro no período de 2006 a 2022. A base será expandida com a coleta de novos dados textuais atualizados, extraídos de fontes como Infomoney, Valor Econômico e Exame.

A aquisição dos dados será realizada com o framework *Scrapy*, uma biblioteca Python de código aberto voltada à raspagem de dados da web de forma estruturada. As informações extraídas serão armazenadas e organizadas em um banco de dados não relacional MongoDB, que oferece flexibilidade e performance no armazenamento de textos não estruturados.

## 5.2 Processamento e Análise dos Dados

Após a coleta, as notícias serão submetidas a uma etapa de pré-processamento utilizando técnicas clássicas de Processamento de Linguagem Natural (PLN), como:

- Tokenização e remoção de stopwords;
- Normalização (lematização ou stemming);
- Identificação de entidades nomeadas.

Em seguida, as notícias serão classificadas por meio do modelo SenFinBERT-PTBR [Santos 2022], uma adaptação do BERT voltada especificamente à análise de sentimentos em textos financeiros escritos em português. O modelo retornará uma polaridade para cada notícia: positiva, negativa ou neutra, permitindo a identificação da percepção do mercado em torno de determinados eventos.

## 5.3 Construção do Algoritmo de Decisão

Com base nos sentimentos atribuídos às notícias ao longo do tempo, será desenvolvido um algoritmo de decisão utilizando a linguagem Python. Esse algoritmo terá como objetivo gerar recomendações automatizadas de compra ou venda de ativos financeiros — especificamente ETFs — em operações do tipo *day trade*, com base na movimentação de sentimentos diários extraída da base.

Para isso, pretende-se testar abordagens supervisionadas e não supervisionadas, bem como algoritmos de aprendizado por reforço. Em especial, serão exploradas as seguintes técnicas:

- **Modelos supervisionados** (para linha de base): Regressão logística e Random Forest, que associam sentimentos e características temporais à direção do movimento do ativo.

- **Aprendizado por Reforço**: Algoritmos como Q-Learning, Deep Q-Network (DQN) e Proximal Policy Optimization (PPO), capazes de lidar com decisões sequenciais e adaptação a diferentes regimes de mercado [Watkins e Dayan 1992, Mnih et al. 2015, Schulman et al. 2017].

O ambiente de simulação de mercado será estruturado como um ambiente de aprendizado por reforço, onde o agente (algoritmo) recebe recompensas baseadas no lucro/prejuízo das decisões tomadas. A função de recompensa levará em consideração não apenas o retorno financeiro, mas também a volatilidade e custos operacionais, como taxa de corretagem.

## 5.4 Avaliação de Eficiência

Para mensurar a performance dos modelos, serão utilizadas métricas financeiras como retorno acumulado, *Sharpe ratio* e *drawdown*. As recomendações serão comparadas ao benchmark da taxa Selic e ao desempenho passivo dos próprios ETFs.

Além disso, será avaliado o grau de estabilidade das estratégias ao longo do tempo, de forma a identificar se há consistência nos retornos ou se os ganhos são esporádicos e instáveis.

## 5.5 Divulgação do Projeto

Ao final do projeto, será elaborado um vídeo explicativo e demonstrativo a ser publicado no YouTube, com o objetivo de divulgar o potencial do uso de tecnologias como PLN e aprendizado por reforço na tomada de decisões financeiras. Espera-se, assim, contribuir para a popularização de ferramentas de inteligência artificial no contexto do investidor individual e educar o público sobre o funcionamento e limitações dessas abordagens.

# 6 Cronograma

Para alcançar o objetivo principal, seguem as oito atividades que serão executadas ao longo de 12 meses, conforme apresentado na Tabela 1.

1. **Revisão bibliográfica:** Estudo de Processamento de Linguagem Natural (PLN), de análise de sentimento e do trabalho de criação da SenFinBERT-PTBR e como se relacionam com finanças e a bolsa de valores.

2. **Coleta de dados:** Extração de notícias e atualizações sobre a área financeira.
3. **Preparo dos dados:** Classificação das notícias armazenadas na base de dados através da Rede Neural SenFinBERT-PTBR.
4. **Desenvolvimento da API:** Criação e execução do código em Python que recomenda a compra e venda de ETFs a partir da base de dados classificada.
5. **Validação do modelo desenvolvido:** Análise do desempenho do programa de recomendações criado.
6. **Planejamento da divulgação da pesquisa:** Criação dos scripts e material usado nos vídeos de divulgação do projeto no YouTube.
7. **Divulgação da pesquisa:** Gravação do material de divulgação do projeto e postagem na rede social.
8. **Redação do relatório final:** Compilação dos resultados obtidos, discussão das limitações do estudo e sugestões para pesquisas futuras.

Tabela 1: Cronograma de execução das atividades ao longo de 12 meses

| **Atividades** | **1** | **2** | **3** | **4** | **5** | **6** | **7** | **8** | **9** | **10** | **11** | **12** |
|---|---|---|---|---|---|---|---|---|---|---|---|---|
| Revisão bibliográfica | • | • | • | • | • | • | • | • | • | • | | |
| Coleta de dados | | | • | • | • | | | | | | | |
| Preparo dos dados | | | • | • | • | • | | | | | | |
| Desenvolvimento da API | | | | • | • | • | • | • | • | | | |
| Validação do modelo desenvolvido | | | | | • | • | • | • | • | | | |
| Planejamento da divulgação da pesquisa | | | | | | | • | • | • | | | |
| Divulgação da pesquisa | | | | | | | | | • | • | | |
| Redação do relatório final | | | | | | | | | | | • | • |

# 7 Resultados Esperados

Espera-se que a ampliação da base de dados contribua significativamente para análises mais robustas, permitindo a inclusão de informações recentes e diversificadas sobre o mercado financeiro. Com isso, a aplicação do modelo de PLN FinBERT-PTBR deverá classificar com alta acurácia o sentimento das novas postagens, possibilitando a extração de padrões relevantes de opinião. A partir dessas classificações, pretende-se que o algoritmo desenvolvido em Python seja capaz de gerar sinais de compra e venda de ETFs,

otimizando decisões no contexto de *day trade*. Espera-se que tais recomendações superem ou se equiparem à taxa SELIC em termos de rentabilidade, com menor volatilidade. Por fim, espera-se que a divulgação dos resultados por meio de vídeos no YouTube promova maior compreensão pública sobre como tecnologias de PLN podem auxiliar na tomada de decisões financeiras, contribuindo tanto para o avanço científico quanto para a educação financeira da sociedade.

# Referências


[Almiñana 2022]ALMIñANA, C. C. *Algoritmo de aprendizado por reforço em estratégia de negociação de ações em alta frequência*. 2022. Trabalho acadêmico, instituição não especificada.

[Capati 2021]CAPATI, F. A. *Aprendizado por reforço profundo multiagente aplicado a negociação de ativos de mercado financeiro*. 2021. Trabalho acadêmico, instituição não especificada.

[Deng et al. 2016]DENG, Y. et al. Deep direct reinforcement learning for financial signal representation and trading. *IEEE Transactions on Neural Networks and Learning Systems*, v. 28, n. 3, p. 653–664, 2016.

[Filho 2022]FILHO, L. H. B. *Usando Algoritmos de trading com o Python*. 2022. Acesso em: 11 jun. 2025. Disponível em: <https://analisemacro.com.br/mercado-financeiro/usando-algoritmos-de-trading-com-o-python/>.

[Hambly, Xu e Yang 2023]HAMBLY, B.; XU, R.; YANG, H. Recent advances in reinforcement learning in finance. *Mathematical Finance*, v. 33, n. 3, p. 437–503, 2023.

[IA Expert 2020]IA Expert. *BERT, o modelo de processamento de linguagem natural que revolucionou a área*. 2020. Acesso em: 11 jun. 2025. Disponível em: <https://iaexpert.academy/2020/04/27/bert-o-modelo-de-processamento-de-linguagem-natural-que-revolucionou-a-area/>.

[Jiang, Olmo e Atwi 2024]JIANG, Y.; OLMO, J.; ATWI, M. Deep reinforcement learning for portfolio selection. *Global Finance Journal*, v. 62, p. 101016, 2024.

[Lommers, Harzli e Kim 2021]LOMMERS, K.; HARZLI, O. E.; KIM, J. *Confronting machine learning with financial research*. 2021. `https://arxiv.org/abs/2103.00366`. ArXiv:2103.00366.

[Martins 2014]MARTINS, R. Processamento de linguagem natural: Fundamentos e aplicações. *Revista de Informática Teórica e Aplicada*, v. 21, n. 2, p. 45–60, 2014.

[Mnih et al. 2015]MNIH, V. et al. Human-level control through deep reinforcement learning. *Nature*, v. 518, n. 7540, p. 529–533, 2015.

[MongoDB Docs 2025]MONGODB Docs. 2025. Acesso em: 11 jun. 2025. Disponível em: <https://www.mongodb.com/pt-br/docs/manual/introduction/>.

[Moody e Saffell 2001]MOODY, J.; SAFFELL, M. Learning to trade via direct reinforcement. *IEEE Transactions on Neural Networks*, v. 12, n. 4, p. 875–889, 2001.

[Nevmyvaka, Feng e Kearns 2006]NEVMYVAKA, Y.; FENG, Y.; KEARNS, M. Reinforcement learning for optimized trade execution. In: *Proceedings of the 23rd International Conference on Machine Learning (ICML)*. [S.l.: s.n.], 2006. p. 673–680.

[Oliveira 2024]OLIVEIRA, M. S. *Modelo contextual de negociação no mercado de ações brasileiro com algoritmo de aprendizado por reforço profundo*. 2024. Trabalho acadêmico, instituição não especificada.

[Oliveira 2020]OLIVEIRA, R. A. de. *Agente de aprendizado por reforço tabular para negociação de ações*. 2020. Trabalho acadêmico, instituição não especificada.

[Park e Irwin 2004]PARK, C.-H.; IRWIN, S. H. The profitability of technical analysis: A review. *AgMAS Project Research Report*, 2004.

[Rao e Jelvis 2022]RAO, A.; JELVIS, T. *Foundations of Reinforcement Learning with Applications in Finance*. [S.l.]: Chapman and Hall/CRC, 2022.

[Rezende 2003]REZENDE, S. O. *Redes Neurais e Algoritmos Genéticos*. [S.l.]: Editora Manole, 2003.

[Santos 2022]SANTOS, L. L. *FinBERT-PTBR: uma abordagem baseada em BERT para análise de sentimentos de textos financeiros em português*. Dissertação (Dissertação de Mestrado) — Universidade de São Paulo, 2022.

[Schulman et al. 2017]SCHULMAN, J. et al. *Proximal Policy Optimization Algorithms*. 2017. `https://arxiv.org/abs/1707.06347`. ArXiv preprint arXiv:1707.06347.

[Scrapy - PyPI 2025]SCRAPY - PyPI. 2025. Acesso em: 11 jun. 2025. Disponível em: <https://pypi.org/project/Scrapy/>.

[Sutton e Barto 2018]SUTTON, R. S.; BARTO, A. G. *Reinforcement Learning: An Introduction*. [S.l.]: MIT Press, 2018.

[Watkins e Dayan 1992]WATKINS, C. J.; DAYAN, P. Q-learning. *Machine Learning*, v. 8, n. 3-4, p. 279–292, 1992.